

Artificial Intelligence: Pengantar Tanpa Basa-Basi

v0.1

Edisi Bahasa Indonesia

David Hutasoit

September 2026

Ringkasan

Kecerdasan buatan atau Artificial Intelligence (AI) mendominasi perbincangan publik saat ini, tetapi sering kali diselimuti promosi berlebihan, fiksi ilmiah, dan jargon terlalu teknis. Artikel ini menawarkan pengantar yang lugas untuk pembaca yang ingin memahami AI tanpa harus menjadi ahli. Ia membahas dasar-dasar kecerdasan mesin, menjelaskan mekanisme teknis di balik sistem yang dipakai saat ini, dan secara jujur mengakui batas-batas pemahaman kita. Artikel ini bukan ramalan dan bukan promosi. Tujuannya adalah membekali pembaca untuk menilai klaim tentang AI dan berpartisipasi secara bermakna dalam membentuk arah teknologinya.

Versi lengkap dalam bahasa Inggris, termasuk notebook Python yang mereproduksi setiap eksperimen, tersedia di https://github.com/davidteaching/no-nonsense_intro_ai/.

Daftar Isi

1	Pembukaan: Mengapa AI Perlu Dipahami, Bukan Hanya Dibicarakan	2
1.1	Rumor dan kenyataan	2
1.2	Mengapa artikel ini berbeda	2
1.3	Untuk siapa artikel ini ditulis	3
2	Apa Itu AI, dan Apa yang Bukan	3
2.1	Istilah yang bersarang, bukan sinonim	4
2.2	Sempit, umum, dan spekulatif	5
2.3	Tiga kesalahpahaman yang perlu diluruskan	6
2.4	Definisi baku	7
2.5	Catatan tentang istilah	7

3	Bagaimana AI Belajar	7
3.1	Data, contoh, dan label	7
3.2	Lima langkah yang menjelaskan hampir semua AI	9
3.3	Mengapa ukuran data, bukan kepintaran algoritma, yang sering menentukan	11
4	Mengapa AI Bekerja, tetapi Tidak Sepenuhnya Kita Pahami	12
4.1	Teka-teki generalisasi	12
4.2	<i>Double descent</i> dan <i>grokking</i> : dua contoh aneh	13
4.3	Kemampuan yang muncul tiba-tiba, atau hanya tampak demikian?	15
4.4	Ringkasan yang jujur	15
5	Kegagalan yang Paling Sering Terjadi Bukan Kegagalan Model	16
5.1	Pergeseran distribusi: ketika dunia berubah	16
5.2	Tiga contoh: kesehatan, perekrutan, moderasi konten	17
5.3	Pelajaran: model hanyalah satu komponen	18
6	Etika, Kebijakan, dan Tata Kelola	19
6.1	Keadilan yang tidak bisa dipenuhi sekaligus	19
6.2	Privasi dan hak atas data	20
6.3	Kebijakan: siapa yang berhak memutuskan?	21
6.4	Kesenjangan antara prinsip dan praktik	22
7	Masa Depan: Skenario, Bukan Ramalan	22
7.1	Pertanyaan yang tidak bisa dijawab	23
7.2	Tiga skenario yang layak dipertimbangkan	23
7.3	Yang tidak boleh diabaikan: konsentrasi kekuatan	24
7.4	Skenario bukan takdir	25
8	Ajakan: Apa yang Bisa anda Lakukan	26
8.1	Enam pertanyaan untuk menilai klaim tentang AI	26
8.2	Di mana mencari informasi lebih lanjut	27
8.3	Penutup	28
A	Catatan tentang Istilah	29
B	Bacaan Lebih Lanjut	31
B.1	Catatan Penutup	32

1 Pembukaan: Mengapa AI Perlu Dipahami, Bukan Hanya Dibicarakan

Kecerdasan buatan adalah teknologi yang langka dalam satu hal: ia dibicarakan di mana-mana, tetapi jarang dijelaskan dengan memadai. Wacana publik bergerak antara dua kutub yang sama-sama tidak menyenangkan. Di satu sisi, ada janji berlebihan: AI akan menyembuhkan penyakit, mempersonalisasi pendidikan, mempercepat penemuan ilmiah. Di sisi lain, ada peringatan tentang mesin yang suatu hari akan melampaui atau menggantikan manusia. Di antara kedua kutub itu, ada kenyataan yang jauh lebih tenang: jutaan orang memakai sistem statistik yang mengklasifikasi gambar, menyusun hasil pencarian, menerjemahkan bahasa, merekomendasikan video, dan membantu menulis, menggambar, serta menyusun kode.

Kesenjangan antara wacana dan kenyataan itu bukan soal tingkat. Ia adalah kesenjangan pemahaman tentang bagaimana sistem ini bekerja, apa yang bisa dan tidak bisa dilakukannya, dan mengapa. Artikel ini adalah usaha untuk menutup kesenjangan itu.

1.1 Rumor dan kenyataan

Setiap generasi riset AI melahirkan gelombang kehebohan, disusul kekecewaan, disusul periode konsolidasi yang lebih tenang. Pola ini sebenarnya sudah pernah terjadi dan sudah punya nama, yaitu "musim dingin AI" (*AI winter*), dan sudah cukup tua sehingga para peneliti serius belajar bersikap skeptis terhadap janji maupun kepanikan. Meskipun demikian, setiap gelombang membawa audiens baru yang belum pernah melihat polanya: jurnalis, pembuat kebijakan, mahasiswa, profesional di bidang yang berdekatan, dan pembaca umum yang menemukan topik ini lewat berita dan peluncuran produk, bukan lewat makalah riset.

Masalahnya bukan bahwa pembaca-pembaca ini kurang informasi. Masalahnya adalah bahan bacaan yang tersedia cenderung jatuh ke dalam dua kategori yang sama-sama tidak memuaskan. Di satu ujung, ada tulisan teknis yang mengandaimatematika tingkat pascasarjana. Di ujung lain, ada tulisan populer yang menjelaskan AI lewat metafora, seperti "otak adalah jaringan saraf" atau "model ini belajar seperti anak kecil", yang sering menyesatkan dan kadang-kadang sepenuhnya salah. Tidak ada kategori yang melayani pembaca yang ingin memahami apa yang sebenarnya terjadi di dalam sistem ini, tanpa menyederhanakan sampai terdistorsi dan tanpa terlalu rumit dan tenggelam dalam notasi.

Artikel ini menempati ruang di antara kedua kategori itu. Ia mengandaimatematika tingkat menengah, tetapi tidak mengandaimatematika tingkat pascasarjana. Ia memakai matematika di tempat matematika menjelaskan, dan memakai prosa di tempat prosa memadai. Ia jujur tentang apa yang sudah diketahui, apa yang masih berupa konvensi rekayasa, dan apa yang benar-benar masih terbuka.

1.2 Mengapa artikel ini berbeda

Ada tiga hal yang membedakan artikel ini dari kebanyakan pengantar AI yang beredar.

Pertama, artikel ini tidak menjanjikan dan tidak menakut-nakuti. Ia tidak akan memberi tahu Anda bahwa AI akan menyelesaikan semua masalah manusia, dan tidak akan memberi tahu Anda bahwa AI akan mengakhiri peradaban. Ia akan menjelaskan apa yang sedang terjadi, dan membiarkan Anda menilai sendiri.

Kedua, artikel ini jujur tentang apa yang belum kita pahami. Ini jarang terjadi di tulisan populer tentang AI. Sebagian besar artikel populer menyajikan AI sebagai teknologi yang sudah mapan dan tinggal diterapkan. Kenyataannya berbeda. Ada banyak hal tentang AI modern yang bekerja sangat baik tetapi tidak sepenuhnya bisa dijelaskan mengapa. Mungkin seiring waktu, manusia akan menemukan penjelasan yang lebih memuaskan. Tapi inilah gambaran sebenarnya saat ini.

Ketiga, artikel ini menyediakan alat. Ia tidak hanya memberi tahu anda fakta tentang AI; ia juga memberi anda cara untuk menilai klaim tentang AI yang akan anda temui setelah selesai membaca. Enam pertanyaan di Bagian 8 bisa anda pakai pada setiap berita, iklan, atau pernyataan pejabat tentang AI yang muncul di hadapan anda.

1.3 Untuk siapa artikel ini ditulis

Artikel ini ditulis untuk pembaca yang serius tetapi bukan spesialis. Audiens yang saya bayangkan meliputi beberapa kelompok.

Jurnalis yang harus meliput AI tanpa harus menjadi ahli, dan yang membutuhkan kerangka untuk menilai klaim yang datang dari perusahaan teknologi atau narasumber lain. Profesional non-teknis, seperti dokter, pengacara, guru, dan pegawai pemerintah, yang pekerjaannya akan bersinggungan dengan sistem AI dan yang perlu tahu apa yang sedang mereka hadapi. Pembuat kebijakan dan pejabat publik yang perlu memahami implikasi teknologi ini tanpa harus membaca literatur teknis penuh. Dan pembaca umum yang penasaran: ibu rumah tangga, siswa, atau siapa saja yang ingin memahami topik ini dengan lebih baik daripada yang ditawarkan oleh berita utama.

Pembaca tidak perlu punya latar belakang matematika. Beberapa konsep dalam artikel ini memiliki akar teknis, tetapi semuanya bisa dijelaskan dalam bahasa sehari-hari. Di mana sebuah istilah teknis tidak bisa dihindari, saya menjelaskannya sekali dan memakainya secara konsisten setelah itu.

Satu catatan tentang kedalaman. Artikel ini bukan pengganti artikel bahasa Inggris yang menjadi rujukannya. Artikel bahasa Inggris menjelaskan mekanisme dengan lebih rinci, menyertakan persamaan, dan disertai notebook Python yang mereproduksi setiap eksperimen. Artikel ini adalah pintu masuknya. Di akhir setiap bagian, saya menunjukkan ke bagian mana dari artikel bahasa Inggris pembaca bisa merujuk jika ingin pembahasan lebih dalam.

Bagian berikutnya mulai dari tempat yang paling dasar: **menyepakati apa yang kita maksud ketika kita mengatakan "AI".**

2 Apa Itu AI, dan Apa yang Bukan

Istilah "kecerdasan buatan" sudah dipakai begitu luas sehingga hampir kehilangan makna. Ia muncul di iklan produk, dokumen regulasi, debat filsafat, dan percakap-

an sehari-hari, dan sering kali berarti hal yang berbeda di masing-masing tempat. Sebelum kita bisa membicarakan apa yang AI dapat dan tidak dapat lakukan, kita perlu menyepakati apa yang sedang kita bicarakan.

Bagian ini menyusun kosakata dasar, membedakan beberapa istilah yang sering dicampuradukkan, dan meluruskan beberapa kesalahpahaman yang sudah sering terjadi.

2.1 Istilah yang bersarang, bukan sinonim

Empat istilah yang paling sering dipakai, yaitu AI, *machine learning*, *deep learning*, dan AI generatif, sebenarnya bersarang, bukan bersinonim. Masing-masing adalah bagian dari yang lain.

Kecerdasan buatan (AI). Istilah paling luas. Ia merujuk pada setiap usaha membuat mesin menjalankan tugas yang, jika dilakukan manusia, dianggap memerlukan kecerdasan: pengenalan gambar, penerjemahan bahasa, permainan catur, perencanaan, dan sebagainya. Istilah ini didefinisikan oleh ambisinya, bukan oleh metodenya. Ia sudah dipakai untuk sistem yang sangat berbeda, dari pembuktian teorema di tahun 1950-an sampai model bahasa di tahun 2020-an.


Pembelajaran mesin (*machine learning*). Bagian dari AI. Mesin pembelajar dirancang untuk tidak diprogram dengan aturan eksplisit, melainkan *belajar* pola dari data. Programmer menentukan arsitektur model dan tujuannya; proses pelatihan menyesuaikan parameter model agar hasilnya semakin baik. Hampir semua kemajuan AI dalam dua dekade terakhir datang dari pembelajaran mesin, yang membuat kedua istilah ini sering dipakai bergantian. Kebiasaan itu menyamarkan fakta bahwa AI juga mencakup pendekatan yang tidak berbasis pembelajaran, misalnya sistem berbasis aturan logika yang mendominasi bidang ini sampai dasawarsa 1980-an.

Pembelajaran mendalam (*deep learning*). Bagian dari pembelajaran mesin. Ia menggunakan *artificial neural network*, atau "jaringan saraf tiruan", dengan banyak lapisan. Kata "mendalam" merujuk pada kedalaman komposisi: setiap lapisan mengubah keluaran lapisan sebelumnya, dan lapisan-lapisan akhir mewakili fitur yang semakin abstrak. *Deep learning* menjadi dominan sekitar tahun 2012, ketika ia jauh mengungguli metode sebelumnya dalam pengenalan gambar, dan sejak itu ia menyebar ke hampir setiap bidang AI.

AI generatif. Kategori yang didefinisikan oleh keluarannya, bukan oleh metodenya. Sistem ini menghasilkan konten baru, seperti teks, gambar, suara, dan kode, bukan hanya mengklasifikasi atau memprediksi. Model bahasa besar, model difusi, dan pembuat gambar adalah contoh utamanya. Tetapi AI generatif bukan keluarga algoritma tersendiri: model generatif dapat dibangun dari blok yang sama dengan pengklasifikasi, dan batas antara keduanya sering kabur. Yang membedakannya adalah apa yang dihasilkan, bukan bagaimana ia dibangun.

Mengapa perbedaan ini penting? Karena pernyataan tentang "AI" sering kali hanya berlaku untuk salah satu bagiannya. Klaim tentang *deep learning* belum tentu berlaku untuk AI simbolik; klaim tentang model bahasa belum tentu berlaku untuk *reinforcement learning*. Ketepatan di sini sangat penting. Ia adalah perbedaan antara klaim yang bermakna dan slogan belaka.

Gambar 1 menunjukkan taksonomi AI.



Gambar 1: Empat istilah yang sering dicampuradukkan. Pembelajaran mesin adalah bagian dari AI, pembelajaran mendalam adalah bagian dari pembelajaran mesin, dan AI generatif adalah kategori yang didefinisikan oleh keluarannya, bukan oleh metodenya. Karena itu wilayah AI generatif melintasi batas pembelajaran mendalam: sebuah model generatif dapat dibangun dari keluarga model apa pun, dalam maupun dangkal. Yang membedakannya adalah apa yang dihasilkan, bukan bagaimana ia dibangun.

2.2 Sempit, umum, dan spekulatif

Ada perbedaan kedua yang sama pentingnya, dan sering diabaikan: seberapa luas kemampuan suatu sistem.

AI sempit. *artificial narrow intelligence* Menjalankan satu tugas tertentu atau sekelompok tugas yang berkaitan, biasanya dalam domain yang jelas. Pengklasifikasi gambar, pengenalan suara, mesin rekomendasi, mesin catur, dan model bahasa semuanya sempit dalam pengertian ini. Bahkan model bahasa yang bisa membicarakan apa saja tetap sempit: ia melakukan satu hal, yaitu memprediksi *token*, atau potongan kata, berikutnya dalam urutan. Bisa jadi model bahasa memberikan kesan "umum", namun ini datang dari luasnya data pelatihan, bukan dari arsitektur yang benar-benar serbaguna.

Kecerdasan umum buatan (AGI). *artificial general intelligence* Sistem hipotetis yang dapat mempelajari dan menjalankan setiap tugas intelektual yang bisa dilakukan manusia, memindahkan pengetahuan antar domain tanpa pelatihan ulang. Sistem seperti ini belum ada. Apakah ia bisa dicapai, bagaimana kita akan mengenalinya jika tercapai, dan apa artinya jika ia tiba, semuanya masih diperdebatkan. Yang jelas untuk saat ini adalah bahwa AI kontemporer, termasuk sistem yang paling mengesankan, tetap sempit.

Superinteligensi. *superintelligence* Sistem hipotetis yang kemampuannya jauh melampaui manusia terbaik di semua bidang yang relevan. Ia adalah subjek spekulasi serius dan ketidaksepakatan serius. Ia bukan target rekayasa, dan tidak ada sistem saat ini yang berada di jalur yang masuk akal menuju ke sana. Ia muncul di artikel ini hanya dalam konteks debat tentang risiko jangka panjang, dan kita akan bersikap eksplisit ketika sedang membicarakan spekulasi, bukan fakta.

Kerancuan dalam menggunakan ketiga kategori ini adalah salah satu sumber kesalahpahaman paling umum. Ketika sebuah berita mengklaim "AI kini dapat melakukan X", yang dimaksud biasanya adalah sistem sempit yang menjalankan versi spesifik dari X dalam kondisi spesifik. Itu bisa tetap bermakna. Tetapi itu bukan kemampuan umum.

2.3 Tiga kesalahpahaman yang perlu diluruskan

AI bukan kesadaran. Sistem saat ini tidak memiliki pengalaman subjektif, tidak memiliki perasaan, dan tidak memiliki tujuan sendiri. Ketika sebuah model bahasa menulis "saya ingin", ia sedang menghasilkan lanjutan teks yang masuk akal secara statistik, bukan melaporkan keadaan internalnya. Apakah mesin *bisa* sadar adalah pertanyaan filosofis yang sah, tetapi pertanyaan itu berbeda dari pertanyaan teknis tentang apa yang dilakukan sistem saat ini. Mencampuradukkan keduanya menyebabkan dua kesalahan sekaligus: menganggap chatbot sebagai pribadi, atau meremehkan kemampuan nyata karena kemampuan itu tidak disertai pemahaman. Perlu dipahami, bahwa sebuah sistem AI bisa memiliki "competence" namun tidak memiliki "comprehension".

AI bukan sihir. Setiap kemampuan sistem modern berasal dari kombinasi arsitektur, data, optimisasi, dan daya komputasi. Semua itu adalah pilihan rekayasa, dan semuanya dapat diperiksa. Fakta bahwa representasi internal sebuah sistem sulit ditafsirkan manusia tidak membuat sistem itu misterius; ia hanya rumit. Artikel ini akan menunjukkan, dengan kode yang bisa dijalankan, dari mana kemampuan itu berasal.

AI bukan agen otonom. Sebagian besar sistem yang disebut AI tidak memiliki tujuan di luar sasaran yang dilatihkan kepadanya. Pengklasifikasi gambar tidak "ingin" mengklasifikasi gambar; ia menghitung sebuah fungsi. Model bahasa tidak "memutuskan" apa yang akan dikatakan; ia mengambil sampel dari distribusi probabilitas. Ini penting karena mengaitkan kehendak pada sistem yang tidak memilikinya mendistorsi diskusi teknis dan debat kebijakan. Pertanyaan apakah sistem di

masa depan bisa memperoleh agensi sungguhan adalah pertanyaan penting, tetapi ia tidak boleh dicampur dengan perilaku sistem yang hanya *tampak* seperti agen.

2.4 Definisi baku

Untuk keperluan artikel ini, kita akan memakai definisi berikut:

AI merujuk pada sistem komputasi yang menjalankan tugas-tugas yang biasanya dikaitkan dengan perilaku cerdas, umumnya dengan mempelajari pola statistik dari data, bukan dengan mengikuti aturan yang diprogram secara eksplisit.

Definisi ini sengaja dibuat sederhana. Ia tidak mengatakan apa-apa tentang kesadaran, keluasan kemampuan, atau otonomi. Ia mengakui bahwa tugas-tugas itu didefinisikan oleh penilaian manusia. Apa yang dianggap “cerdas” adalah target yang bergerak. Dan ia menempatkan mekanismenya pada pembelajaran dari data, yang merupakan sumber hampir semua kemampuan AI kontemporer.

2.5 Catatan tentang istilah

Beberapa istilah teknis yang akan sering muncul dalam artikel ini memiliki padanan bahasa Indonesia yang sudah lazim, dan beberapa tidak. Kebijakan yang saya pakai adalah: gunakan padanan Indonesia jika ia akurat dan dipahami; tetap gunakan istilah Inggris jika padanannya terasa dipaksakan; dan jelaskan istilah Inggris sekali saat pertama kali muncul.

Contoh-contoh yang paling sering muncul: *machine learning* diterjemahkan menjadi *pembelajaran mesin*, *deep learning* menjadi *pembelajaran mendalam*, *neural network* menjadi *jaringan saraf*. Sebaliknya, *transformer*, *token*, *prompt*, dan *fine-tuning* dibiarkan dalam bahasa Inggris karena padanan Indonesianya jarang dipakai dan justru membingungkan. Daftar lengkapnya ada di Lampiran A.

Pembaca yang ingin versi lebih lengkap dari argumen di bagian ini, termasuk rujukan ke literatur teknis dan pembahasan sejarah simbolik-versus-koneksionis, dapat menemukannya di artikel bahasa Inggris pada Bagian 2.

3 Bagaimana AI Belajar

Bagian sebelumnya menyepakati apa yang kita maksud dengan AI. Bagian ini menjelaskan bagaimana AI belajar. Ini adalah bagian terpenting dari artikel ini, karena di sinilah pembaca bisa mulai melihat bahwa AI bukan sihir. Sistem ini bekerja dengan cara yang bisa dijelaskan, dan penjelasan itu tidak memerlukan matematika tingkat lanjut.


3.1 Data, contoh, dan label

Perubahan mendasar yang dibawa pembelajaran mesin (*machine learning*) adalah penggantian aturan eksplisit dengan contoh. Alih-alih menulis aturan seperti "jika

surel mengandung kata ini, tandai sebagai spam", kita mengumpulkan ribuan surel berlabel dan membiarkan algoritma menemukan polanya sendiri. Inilah sumber kekuatannya, dan sekaligus sumber sebagian besar kelemahannya.

Secara formal, kita diberi kumpulan pasangan masukan dan keluaran, dan diminta menemukan fungsi yang memetakan masukan ke keluaran dengan benar untuk masukan baru yang belum pernah dilihat model. Dalam contoh surel tadi, masukannya adalah isi surel, dan keluarannya adalah label "spam" atau "bukan spam".

Gambar 2 menunjukkan contoh yang akan kita pakai sepanjang artikel ini: kumpulan gambar angka tulisan tangan yang dikenal sebagai MNIST, salah satu kumpulan data paling terkenal di bidang ini. Gambar-gambar ini adalah angka dari nol sampai sembilan, ditulis oleh ratusan orang berbeda. Tugasnya adalah membangun model yang, diberi gambar angka, bisa menebak angka yang tertulis di dalamnya.



Gambar 2: Kumpulan data MNIST. Kiri: 25 contoh gambar angka tulisan tangan. Tengah: rata-rata setiap piksel di seluruh kumpulan data. Kanan: simpangan baku setiap piksel. Piksel di tepi gambar hampir tidak membawa informasi, karena warnanya gelap di kedua statistik. Ini adalah gambaran awal tentang pemilihan fitur: tidak semua masukan sama pentingnya, dan menemukan mana yang penting adalah bagian dari masalah pembelajaran itu sendiri.

Tiga hal perlu ditekankan di sini.

Pertama, model dan data adalah proksi untuk realita, bukan realita itu sendiri. Model tidak sama dengan realita. Model yang dilatih pada surel tahun 2019 belum tentu bekerja pada surel tahun 2025. Pengklasifikasi medis yang dilatih pada populasi satu rumah sakit bisa gagal di rumah sakit lain. Kesenjangan antara distribusi data pelatihan dan distribusi data dunia nyata disebut *distribution shift*, atau pergeseran distribusi, dan ia adalah penyebab paling umum kegagalan AI di dunia nyata. Kita akan kembali ke topik ini di Bagian 5.

Kedua, fitur adalah representasi. Sebuah gambar mentah adalah kisi piksel; sebuah surel mentah adalah rangkaian karakter. Tidak ada yang merupakan masukan alami bagi algoritma pembelajaran. Secara historis, praktisi merancang fitur dengan tangan: tepi untuk gambar, rangkaian kata untuk teks, statistik ringkasan untuk data tabular. Pembelajaran mendalam mengubah ini dengan mempelajari fitur langsung dari data mentah, dan itulah salah satu alasan mengapa ia menggantikan sebagian besar alur kerja sebelumnya.

Ketiga, tugasnya bermacam-macam. Klasifikasi memprediksi label diskret, seperti digit nol sampai sembilan. Regresi memprediksi nilai kontinu. Peringkat menyusun urutan. Generasi menghasilkan objek baru. Empat algoritma berbeda bisa berjalan di satu mesin, tetapi fungsi kesalahan dan metrik evaluasinya berbeda.

3.2 Lima langkah yang menjelaskan hampir semua AI

Melatih sebuah model berarti menemukan parameter yang meminimalkan sebuah ukuran kesalahan. Ukuran kesalahan itu disebut fungsi kerugian, atau *loss function*. Ia adalah satu angka yang merangkum seberapa buruk model sedang bekerja. Parameternya adalah angka-angka yang boleh diubah oleh model.


Proses pencarian hampir selalu dilakukan dengan metode yang disebut *gradient descent*, atau penurunan gradien. Cara kerjanya, dalam bahasa sehari-hari, seperti berikut. Bayangkan anda berada di lereng gunung berkabut, dan anda ingin turun ke lembah terendah. Anda tidak bisa melihat seluruh medan, tetapi anda bisa merasakan kemiringan tanah di bawah kaki anda. Anda mengambil langkah kecil ke arah yang paling menurun, merasakan kemiringan lagi, mengambil langkah berikutnya, dan seterusnya. Setelah ribuan langkah, anda berhenti di sebuah lembah. Anda mengetahui anda sedang di sebuah lembah karena anda tidak menemukan kemiringan lagi. Dalam matematika gradient descent, algoritma menganggap gradient descent sudah menemukan fungsi minimal karena tidak menemukan perubahan kemiringan lagi.

Prosedur pelatihan terdiri atas lima langkah yang diulang terus-menerus.

1. **Umpan depan.** Model menerima sekumpulan contoh masukan dan menghasilkan prediksi.
2. **Perhitungan kesalahan.** Prediksi dibandingkan dengan jawaban yang benar, dan fungsi kerugian menghitung seberapa jauh perbedaannya.
3. **Umpan balik.** Sebuah algoritma bernama *backpropagation*, atau perambatan balik, menghitung seberapa besar setiap parameter berkontribusi terhadap kesalahan yang terjadi.
4. **Pembaruan.** Setiap parameter disesuaikan sedikit, ke arah yang mengurangi kesalahan berikutnya.
5. **Pengulangan.** Langkah 1 sampai 4 diulang untuk kumpulan contoh berikutnya, lalu berikutnya, dan seterusnya.

Gambar 3 menunjukkan siklus ini sebagai diagram. Siklus ini adalah inti dari hampir semua AI modern. Model pengklasifikasi angka sederhana yang akan kita lihat menggunakan siklus ini. Model bahasa besar yang mendasari *chatbot* modern juga menggunakan siklus ini. Yang berbeda hanyalah ukuran model, jumlah data, dan jumlah pengulangan.


Perlu ditekankan bahwa tidak ada aturan manusia yang ditulis di dalam proses ini. Tidak ada yang memberi tahu model bahwa angka tujuh biasanya punya dua garis horizontal. Tidak ada yang memberi tahu model bahwa angka satu biasanya



Gambar 3: Siklus pelatihan yang menjadi inti hampir semua AI modern. Sebuah model membuat prediksi, prediksi itu dibandingkan dengan jawaban yang benar, kesalahannya diukur, dan parameter model disesuaikan sedikit agar kesalahan berikutnya lebih kecil. Proses ini diulang jutaan kali. Setiap model dalam artikel ini, dari pengklasifikasi sederhana sampai model bahasa besar (*large language model (LLM)*), adalah penyempurnaan dari siklus yang sama.

berupa garis vertikal tunggal. Model menemukan semua itu sendiri dari data. Setelah pelatihan selesai, parameter-parameter yang dipelajari bisa diperiksa. Mereka adalah angka-angka, tidak lebih dan tidak kurang.

Gambar 4 menunjukkan apa yang terjadi ketika kita melatih model paling sederhana pada kumpulan data MNIST. Model ini disebut regresi logistik. Ia hanya punya satu lapisan, yaitu lapisan linear yang diikuti fungsi pengaktifan. Setelah beberapa ratus pengulangan, model mencapai akurasi sekitar 92% pada data uji.



Gambar 4: Regresi logistik pada MNIST, dilatih dari awal dengan NumPy. Kiri: fungsi kerugian turun dengan lancar selama 500 langkah. Kanan: matriks bobot yang telah dipelajari, dibentuk ulang menjadi sepuluh templat berukuran 28×28 , satu untuk setiap kelas digit. Piksel merah mendorong masukan ke arah kelas tersebut; piksel biru mendorongnya menjauh. Penurunan gradien menghasilkan templat yang bisa ditafsirkan manusia, tanpa satu pun instruksi manual tentang piksel mana yang penting.

Yang menarik bukan angka 92%-nya, tetapi fakta bahwa templat yang dipelajari bisa ditafsirkan. Setiap kolom dari matriks bobot, ketika dibentuk ulang menjadi gambar 28×28 , terlihat seperti angka. Templat untuk kelas "nol" memang terlihat seperti angka nol. Templat untuk kelas "satu" memang terlihat seperti angka satu. Penurunan gradien, mulai dari bobot acak, mencocokkan 7.850 angka sampai templatnya mengklasifikasi digit dengan baik. Tidak ada aturan apa pun di dalam kode tentang piksel mana yang penting. Aturan itu muncul dari data.

Jika anda hanya mengingat satu hal dari bagian ini, ingatlah yang berikut: ***AI belajar dengan menyesuaikan angka, sedikit demi sedikit, sampai kesalahannya mengecil.*** Tidak ada yang lebih mistis dari itu.

3.3 Mengapa ukuran data, bukan kepintaran algoritma, yang sering menentukan

Di dekade terakhir, komunitas riset menemukan sesuatu yang awalnya mengagetkan: performa model AI bertumbuh secara teratur dengan tiga faktor. Pertama, ukuran model, diukur dari jumlah parameternya. Kedua, ukuran dan keragaman data pelatihan. Ketiga, daya komputasi yang dipakai untuk melatih model. Ketika ketiganya dinaikkan bersamaan, kesalahan model turun mengikuti pola yang bisa diprediksi. Pola ini disebut *scaling laws*, atau hukum skala.

Implikasi praktisnya signifikan. Jika anda bisa memprediksi seberapa baik sebuah model akan bekerja sebelum melatihnya, keputusan tentang anggaran komputasi menjadi keputusan bisnis, bukan hanya keputusan teknis. Dan yang lebih penting untuk audiens awam: penambahan data sering kali lebih berharga daripada penambahan kepintaran arsitektur. Sebuah model yang sederhana tetapi dilatih pada data yang sangat banyak sering kali mengalahkan model canggih yang dilatih pada data yang lebih sedikit.

Ini menjelaskan mengapa perusahaan-perusahaan besar berlomba mengumpulkan data. Ini juga menjelaskan mengapa model bahasa besar memerlukan korpus yang sedemikian besar: bukan karena arsitekturnya ajaib, tetapi karena skala data memungkinkan kemampuan yang tidak muncul pada skala kecil. Hukum skala bukan sihir; ia adalah pola empiris yang berulang, dan kita akan kembali ke keterbatasannya di Bagian 4.

Pembaca yang ingin versi lebih rinci dari bagian ini, termasuk persamaan matematis yang mendasari penurunan gradien dan kode NumPy yang bisa dijalankan sendiri, dapat merujuk ke artikel bahasa Inggris pada Bagian 5 dan notebook yang menyertainya.

4 Mengapa AI Bekerja, tetapi Tidak Sepenuhnya Kita Pahami

Bagian sebelumnya menjelaskan bagaimana AI belajar. Penjelasan itu akurat, tetapi tidak lengkap. Ada satu hal yang jarang disampaikan dalam pengantar AI untuk pembaca awam: kita bisa membangun sistem AI modern dan kita tahu persis bagaimana melatihnya, tetapi kita tidak sepenuhnya memahami mengapa ia bekerja sebaik itu. Ini bukan kelemahan artikel ini. Ini adalah keadaan sebenarnya dari bidangnya, dan mengakuinya secara jujur adalah bagian dari sikap tanpa basa-basi yang dijanjikan di Bagian 1.

4.1 Teka-teki generalisasi

Mulailah dari sebuah pengamatan sederhana. Sebuah model dengan jumlah parameter yang jauh lebih banyak daripada jumlah contoh pelatihannya seharusnya "menghafal" data pelatihan, bukan mempelajari pola yang bisa digeneralisasi ke data baru. Dalam teori statistik klasik, model seperti itu disebut *overfit*, dan ia seharusnya gagal total ketika diberi contoh yang belum pernah dilihat.

Tetapi model AI modern tidak gagal. Model bahasa besar punya ratusan miliar parameter atau lebih, dilatih pada kumpulan data yang jauh lebih kecil daripada jumlah parameternya, dan tetap mampu menjawab pertanyaan tentang topik yang tidak ada di data pelatihannya. Model penglihatan komputer yang dilatih pada beberapa juta gambar mampu mengenali objek dalam gambar yang belum pernah dilihatnya. Secara teori, semua ini seharusnya tidak mungkin. Secara empiris, semuanya terjadi setiap hari.

Inilah teka-teki generalisasi. Bagaimana mungkin model yang cukup besar untuk menghafal seluruh data pelatihannya justru mempelajari sesuatu yang lebih dari hafalan?

Para peneliti sudah mengusulkan beberapa penjelasan. Tidak ada yang lengkap, tetapi masing-masing menyumbang sebagian gambaran. Regularisasi, misalnya penalti terhadap parameter besar, membatasi seberapa rumit model. Penghentian awal pelatihan sebelum kesalahan pelatihan mencapai nol menghindari hafalan. Dan algoritma penurunan gradien sendiri, menurut beberapa penelitian, memiliki kecenderungan bawaan untuk menemukan solusi yang sederhana dan bisa digeneralisasi, bukan solusi rumit yang hanya cocok untuk data pelatihan. Tetapi tidak satu pun dari penjelasan ini yang sepenuhnya menjelaskan mengapa model berukuran ratusan miliar parameter bisa bekerja sebaik itu.

Yang penting untuk pembaca awam di sini bukan detail teknis penjelasannya. Yang penting adalah mengakui bahwa penjelasan lengkapnya belum ada. Ini bukan soal gravitasi kuantum yang sampai saat ini belum dipahami. Ini adalah teknologi yang sudah dipakai di mana-mana, diajarkan di universitas, dan menghasilkan miliaran dolar pendapatan, tetapi teori di belakangnya masih belum tuntas.

4.2 *Double descent* dan *grokking*: dua contoh aneh


Dua fenomena empiris terbaru membuat teka-teki generalisasi semakin nyata. Keduanya tidak diprediksi oleh teori klasik, dan keduanya masih belum dijelaskan sepenuhnya.

Yang pertama disebut *double descent*. Gambaran klasik tentang kompleksitas model dan kesalahan uji adalah kurva berbentuk U: model yang terlalu sederhana kurang cocok untuk data (disebut *underfitting*), model yang terlalu rumit menghafal data (*overfitting*), dan titik terbaik ada di tengah. Tetapi ketika para peneliti menguji model yang jauh lebih besar, mereka menemukan sesuatu yang aneh. Setelah melewati titik di mana model cukup besar untuk menghafal seluruh data pelatihan, kesalahan uji tidak terus naik seperti yang diprediksi. Ia justru turun lagi, dan kadang-kadang mencapai titik terendah yang lebih baik daripada titik optimal yang diprediksi teori klasik.

Gambar 5 menunjukkan kedua gambaran ini berdampingan. Panel kiri adalah kurva klasik yang diajarkan di buku-buku teks. Panel kanan adalah apa yang sebenarnya terjadi pada model modern: kesalahan uji mengikuti kurva klasik sampai titik interpolasi, lalu naik ke puncak, lalu turun lagi untuk kedua kalinya. Dari sinilah nama *double descent* berasal.

Yang kedua disebut *grokking*. Dalam beberapa eksperimen, sebuah model akan tampak menghafal data pelatihannya selama ribuan langkah pelatihan, dengan kesalahan uji yang tinggi dan tidak membaik. Lalu, tiba-tiba, dalam rentang beberapa ratus langkah, kesalahan ujinya anjlok. Model berpindah dari sekadar menghafal ke solusi yang benar-benar bisa digeneralisasi, tanpa peringatan sebelumnya, dan dalam waktu yang sangat singkat dibanding keseluruhan proses pelatihan.

Perpindahan ini bukan semacam kompromi bertahap, di mana model berangsur-angsur membaik. Ia adalah lompatan. Model bisa berada di rezim menghafal selama berhari-hari, lalu melompat ke rezim generalisasi dalam beberapa jam. Tidak ada yang mengubah data, arsitektur, atau algoritma pada saat perpindahan itu terjadi. Sesuatu di dalam proses pelatihan itu sendiri yang berubah, dan kita belum sepenuhnya tahu apa.



Gambar 5: Bias dan varians sebagai fungsi kompleksitas model. **(a)** Dekomposisi klasik. Seiring meningkatnya kompleksitas, bias turun dan varians naik. Jumlah keduanya berbentuk U, dengan minimum pada kompleksitas menengah. Ini adalah kerangka yang dijelaskan di buku-buku teks, dan dikembangkan untuk model di mana kompleksitas bisa diukur dari jumlah parameter. **(b)** Gambaran empiris modern. Kesalahan uji mengikuti kurva U klasik sampai ambang interpolasi, titik di mana model cukup besar untuk mencocokkan data pelatihan dengan sempurna, lalu naik ke puncak sebelum turun lagi. Penurunan kedua ini didokumentasikan pada akhir 2010-an dan tidak diprediksi oleh teori klasik. Mekanismenya masih menjadi pertanyaan terbuka.

Kedua fenomena ini penting untuk pembaca awam karena satu alasan: mereka menunjukkan bahwa sistem AI tidak sepenuhnya dipahami bahkan oleh orang-orang yang membangunnya. Ini bukan berarti AI tidak bisa dipercaya. Ini berarti AI adalah teknologi empiris, dalam pengertian yang sama seperti kedokteran awal abad ke-19: ia bekerja, tetapi teori di baliknya belum matang.

4.3 Kemampuan yang muncul tiba-tiba, atau hanya tampak demikian?

Ada satu klaim lain yang sering muncul dalam diskusi publik tentang AI: bahwa kemampuan tertentu "muncul" secara tiba-tiba pada skala model tertentu, seolah-olah ada ambang batas ajaib yang dilewati. Klaim ini biasanya disebut *emergent abilities*, atau kemampuan yang muncul.

Contoh klaimnya seperti ini. Sebuah model dengan sepuluh miliar parameter sama sekali tidak bisa melakukan operasi aritmetika sederhana. Sebuah model dengan seratus miliar parameter tiba-tiba bisa. Sebuah model dengan satu miliar parameter tidak bisa menerjemahkan kalimat kompleks. Sebuah model dengan sepuluh miliar parameter tiba-tiba bisa. Perpindahan dari tidak bisa menjadi bisa tampak begitu tajam sehingga wajar untuk menduga ada sesuatu yang mendasar berubah pada skala tersebut.

Tetapi sekarang kita masuk ke wilayah di mana kehati-hatian ekstra diperlukan. Beberapa klaim tentang *emergent abilities* ternyata adalah artefak dari cara kita mengukur kemampuan. Sebuah tolok ukur yang memberi nilai hanya jika jawabannya persis benar akan menampakkan model sebagai gagal total selama jawabannya masih sebagian benar, dan tiba-tiba mendapat nilai tinggi begitu jawabannya sepenuhnya benar. Jika tolok ukurnya diubah menjadi memberi nilai sebagian, kurva kemampuannya menjadi mulus, tanpa lompatan apa pun.

Dengan kata lain, sebagian dari apa yang kita lihat sebagai "kemampuan yang muncul tiba-tiba" sebenarnya adalah "kinerja yang tampak melompat karena cara kita menilainya". Apakah ada kemampuan yang benar-benar muncul tiba-tiba, dalam arti bahwa ada perubahan kualitatif di dalam model, atau apakah semuanya hanyalah artefak pengukuran yang halus, masih diperdebatkan.

Posisi yang jujur adalah: kita belum tahu. Ada bukti untuk kedua sisi. Beberapa kemampuan jelas membaik secara bertahap seiring bertambahnya skala. Beberapa tampak muncul tiba-tiba dan tetap muncul tiba-tiba bahkan setelah tolok ukurnya diperbaiki. Tetapi tidak ada konsensus tentang mengapa atau kapan fenomena ini terjadi.

4.4 Ringkasan yang jujur

Marilah kita rangkum apa yang sudah kita ketahui dan apa yang belum.

Yang sudah kita ketahui: kita tahu bagaimana membangun model AI. Kita tahu bagaimana melatihnya, dengan prosedur lima langkah yang dijelaskan di Bagian 3. Kita tahu bahwa performa model bertumbuh secara teratur dengan ukuran, data, dan komputasi. Kita tahu bahwa model AI bisa dipakai untuk berbagai tugas yang tidak dibayangkan sebelumnya.

Yang belum kita ketahui: kita tidak tahu sepenuhnya mengapa model besar bisa digeneralisasi. Kita tidak tahu mengapa *double descent* terjadi. Kita tidak

tahu mengapa *grokking* terjadi. Kita tidak tahu apakah kemampuan yang tampak muncul tiba-tiba benar-benar muncul tiba-tiba, atau hanya tampak demikian karena pengukuran yang tidak tepat. Kita tidak tahu apakah hukum skala akan terus berlaku, atau apakah ada dinding yang akan dihantam pada suatu titik.

Ini bukan daftar yang menyenangkan untuk dibaca, dan bukan daftar yang sering muncul di tulisan populer tentang AI. Tetapi ia adalah daftar yang benar. Perbedaan antara seorang yang memahami AI dan seorang yang hanya mengulang klaim tentang AI terletak tepat di sini: pada kesediaan untuk mengakui apa yang belum diketahui.

Ada satu kekhawatiran yang wajar muncul pada titik ini. Jika kita tidak sepenuhnya memahami mengapa AI bekerja, apakah kita bisa mempercayainya? Jawabannya, mungkin mengejutkan, adalah ya, dengan syarat yang jelas. Kita mempercayai banyak teknologi yang tidak kita pahami sepenuhnya. Kita menerbangkan pesawat sebelum kita memahami aerodinamika dengan lengkap. Kita memakai obat sebelum kita memahami mekanisme kerjanya di tingkat molekuler. Yang membedakan kepercayaan yang wajar dari kepercayaan yang buta adalah seberapa jauh kita menguji sistem itu pada kondisi yang berbeda, dan seberapa jujur kita tentang di mana ia bisa gagal.

Bagian berikutnya mengangkat pertanyaan itu secara langsung: di mana AI paling sering gagal, dan mengapa kegagalan itu jarang berasal dari model itu sendiri.

Pembaca yang ingin versi lebih rinci dari bagian ini, termasuk pembahasan tentang *grokking* dan *double descent* yang lebih teknis, dapat merujuk ke artikel bahasa Inggris pada Bagian 9.

5 Kegagalan yang Paling Sering Terjadi Bukan Kegagalan Model

Bagian-bagian sebelumnya membahas AI sebagai soal teknis: bagaimana ia belajar, mengapa ia bisa bekerja, dan di mana batas pemahaman kita. Bagian ini mengalihkan perhatian ke hal yang lebih sering menentukan apakah sebuah sistem AI berhasil atau gagal ketika ia sampai ke tangan pengguna. Klaim utamanya lugas: kegagalan sistem AI di dunia nyata jarang berasal dari modelnya. Kegagalan itu berasal dari data, dari lingkungan tempat sistem dipakai, dari insentif di sekitarnya, atau dari asumsi yang tidak pernah diucapkan oleh siapapun yang membangunnya.

Klaim ini penting untuk pembaca yang bukan spesialis, karena sebagian besar diskusi publik tentang AI berfokus pada model: model apa yang dipakai, seberapa besar, seberapa pintar. Padahal jika kita melihat sistem yang benar-benar dipakai di rumah sakit, di kantor pemerintahan, atau di platform media sosial, komponen yang paling sering bermasalah justru bukan modelnya.

5.1 Pergeseran distribusi: ketika dunia berubah


Kita sudah menyinggung topik ini di Bagian 3. Sekarang saatnya membahasnya secara lebih langsung.

Sebuah model dilatih pada data yang dikumpulkan pada suatu waktu, di suatu tempat, dari suatu populasi. Ketika ia dipakai di dunia nyata, ia menghadapi

data yang mungkin berbeda dari data pelatihannya. Model yang dilatih pada surel tahun 2019 menghadapi pola spam tahun 2025 yang belum ada saat itu. Model yang dilatih pada pasien satu rumah sakit menghadapi pasien rumah sakit lain dengan demografi, peralatan, dan praktik pencatatan yang berbeda. Model yang dilatih pada foto siang hari menghadapi foto malam hari. Kesenjangan antara distribusi data pelatihan dan distribusi data di dunia nyata disebut *distribution shift*, atau pergeseran distribusi.

Pergeseran ini adalah penyebab paling umum kegagalan sistem AI di dunia nyata. Ia juga penyebab yang paling sulit dideteksi, karena model tidak memberi tahu anda bahwa ia sedang menghadapi data yang berbeda dari yang pernah ia lihat. Ia hanya memberikan prediksi, dengan tingkat keyakinan yang sama seperti biasa, bahkan ketika prediksinya salah.

Gambar 6 menunjukkan salah satu bentuk pergeseran distribusi yang paling sederhana: memutar gambar angka tulisan tangan sebesar tiga puluh derajat. Bagi pembaca manusia, angka yang diputar tetap mudah dikenali. Bagi model yang dilatih pada angka tegak, akurasi jatuh dari 99% menjadi sekitar 70%. Model tidak tahu bahwa gambar itu diputar. Ia hanya tahu bahwa pola pikselnya tidak cocok dengan pola yang pernah ia pelajari.



Gambar 6: Pergeseran distribusi dalam bentuk yang paling sederhana: gambar uji diputar tiga puluh derajat. Pembaca manusia tidak kesulitan mengenali angkanya. Model yang dilatih pada angka tegak justru kehilangan hampir sepertiga akurasi-nya. Model telah mempelajari statistik piksel pada posisi tertentu, bukan konsep angka yang bisa dikenali dari orientasi apa pun.

Pergeseran distribusi bukan hanya soal gambar. Dalam sistem perekrutan, pergeseran bisa berupa perubahan demografi pelamar selama beberapa tahun. Dalam sistem kredit, pergeseran bisa berupa perubahan kondisi ekonomi. Dalam sistem penerjemahan, pergeseran bisa berupa munculnya istilah baru yang belum ada di data pelatihan. Di setiap kasus, model yang sama, dengan parameter yang sama, menghadapi dunia yang tidak sama.

5.2 Tiga contoh: kesehatan, perekrutan, moderasi konten

Tiga contoh berikut menunjukkan bagaimana pergeseran distribusi dan persoalan lain di sekitar model berujung pada kegagalan yang nyata. Ketiganya diambil dari domain yang berbeda, tetapi polanya sama.

Kesehatan. Sepsis adalah kondisi medis yang berbahaya dan sering tidak terdeteksi pada tahap awal. Beberapa rumah sakit memakai model AI untuk memperingatkan dokter ketika seorang pasien menunjukkan tanda-tanda sepsis. Salah

satu model yang paling luas dipakai dilaporkan dalam evaluasi independen memiliki sensitivitas yang jauh lebih rendah dan tingkat peringatan palsu yang jauh lebih tinggi daripada yang dilaporkan oleh pengembangnya. Penyebabnya bukan algoritma yang salah. Penyebabnya adalah populasi pasien di rumah sakit tempat model dipakai berbeda dari populasi pasien yang dipakai untuk mengembangkan model tersebut.

Kasus ini menunjukkan satu hal yang sering diabaikan: model yang bekerja baik di atas kertas bisa bekerja buruk di lapangan, jika distribusi data di lapangan berbeda dari distribusi data di atas kertas. Dalam dunia kedokteran, perbedaan distribusi ini tidak hanya menurunkan performa; ia bisa berujung pada peringatan yang diabaikan oleh dokter, karena terlalu banyak alarm palsu.

Perekrutan. Sebuah perusahaan teknologi besar pernah membangun sistem AI untuk menyaring lamaran kerja. Sistem itu dilatih pada data lamaran selama sepuluh tahun terakhir, dan belajar dari keputusan rekrutmen manusia yang tercatat di data tersebut. Karena industri teknologi saat itu didominasi oleh laki-laki, sistem menyimpulkan bahwa pola yang berkaitan dengan laki-laki lebih menjanjikan. Ia mulai menghukum riwayat hidup yang memuat kata-kata seperti "kapten klub catur perempuan". Sistem kemudian dihentikan.

Perhatikan bahwa sistem ini tidak merancang biasnya sendiri. Ia hanya belajar dari data yang diberikan. Data itu bukan netral; ia mencerminkan ketidakseimbangan industri selama satu dekade. Ketika data historis yang tidak netral diumpankan ke model yang netral secara matematis, hasilnya adalah bias yang diwarisi dan diperkuat. Ini bukan kegagalan algoritma. Ini kegagalan asumsi yang tidak pernah diperiksa: bahwa data masa lalu bisa dipakai sebagai kebenaran untuk keputusan yang, sejak awal, tidak pernah netral.

Moderasi konten. Platform media sosial memakai model AI untuk menandai konten berbahaya pada skala yang tidak mungkin ditangani manusia. Sistem ini bekerja dengan kecepatan tinggi dan biaya rendah, tetapi mereka gagal dengan cara yang tidak muncul di data pelatihan. Mereka salah menandai satir sebagai ujaran kebencian. Mereka melewatkan bentuk pelecehan baru yang belum mereka kenal. Mereka memburuk dengan cepat ketika pengguna mulai menyesuaikan perilakunya untuk menghindari deteksi.

Yang paling perlu diperhatikan adalah lapisan manusia yang meninjau kembali keputusan model. Lapisan ini sering kekurangan sumber daya, dan pekerjaannya secara psikologis berat. Ketika sistem gagal, yang menanggung beban bukan hanya pengguna yang salah ditandai, tetapi juga pekerja yang harus meninjau ribuan keputusan per hari.

5.3 Pelajaran: model hanyalah satu komponen

Ketiga contoh tadi memiliki pola yang sama, meskipun domainnya berbeda. Dalam setiap kasus, model itu sendiri bukanlah sumber kegagalan yang utama. Kegagalan itu berasal dari data yang dipakai, dari asumsi yang tidak diperiksa, dari lingkungan tempat model dipakai, atau dari insentif di sekitar sistem.

Pelajaran ini bisa dirumuskan dalam satu kalimat: *model adalah satu komponen di dalam sistem yang lebih besar, dan sistem itulah yang paling sering menentukan hasil*. Sistem itu meliputi data, manusia, institusi, insentif, dan proses. Memperbaiki model tanpa memperhatikan sistem jarang menghasilkan perubahan yang diinginkan.

Konsekuensi praktisnya bagi pembaca bukan spesialis ada dua.

Pertama, ketika anda mendengar klaim tentang sebuah sistem AI, jangan hanya bertanya tentang modelnya. Tanyakan juga tentang datanya. Dari mana asalnya? Siapa yang mengumpulkannya? Populasi apa yang diwakilinya? Apakah populasinya sama dengan populasi tempat sistem akan dipakai?

Kedua, ketika anda mendengar bahwa sebuah sistem AI gagal, jangan langsung menyimpulkan bahwa algoritmanya buruk. Sebagian besar kegagalan datang dari tempat lain. Sebuah model yang baik bisa dipakai dengan cara yang buruk, dalam konteks yang salah, atau dengan data yang tidak sesuai. Memperbaiki algoritma tidak akan menolong jika masalahnya ada di tempat lain.

Ini bukan berarti modelnya tidak penting. Model tetap perlu bagus. Tetapi model yang bagus adalah syarat perlu, bukan syarat cukup. Sistem yang berhasil memerlukan lebih dari sekadar model yang bagus: ia memerlukan data yang tepat, asumsi yang diperiksa, lingkungan yang cocok, dan insentif yang selaras.

Pembaca yang ingin versi lebih rinci dari bagian ini, termasuk pembahasan siklus umpan balik, utang teknis, dan pengukuran kinerja model dalam kondisi produksi, dapat merujuk ke artikel bahasa Inggris pada Bagian 8.

6 Etika, Kebijakan, dan Tata Kelola

Bagian sebelumnya membahas kegagalan teknis. Bagian ini membahas kelas persoalan yang berbeda. Bahkan ketika sebuah sistem bekerja persis seperti yang dirancang, ia bisa menimbulkan kerugian, menghasilkan ketidakadilan, atau memusatkan kekuasaan dengan cara yang menuntut pembenaran. Pertanyaan-pertanyaan ini bukan pelengkap. Dalam banyak penerapan, mereka justru alasan mengapa pertanyaan teknis menjadi penting.

Ada tiga jenis klaim yang muncul di bagian ini, dan penting untuk membedakannya. Yang pertama, *kerugian yang terdokumentasi*: kasus-kasus di mana sistem yang sudah dipakai menyebabkan kerusakan yang bisa diukur, dengan bukti yang ada di catatan publik. Yang kedua, *klaim yang diperdebatkan*: konsekuensi yang masuk akal dan sedang dibahas, di mana buktinya belum lengkap dan orang-orang yang beralasan bisa berbeda pendapat. Yang ketiga, *spekulasi*: kekhawatiran tentang masa depan yang belum terwujud, di mana argumennya lebih sering tentang kemungkinan daripada bukti. Memperlakukan yang ketiga seolah-olah yang pertama, atau mengabaikan yang pertama karena yang ketiga bersifat spekulatif, adalah dua kesalahan yang simetris.

6.1 Keadilan yang tidak bisa dipenuhi sekaligus

Kerugian paling terdokumentasi dari AI yang sudah dipakai di masyarakat berhubungan dengan diskriminasi. Salah satu kasus paling banyak dibahas adalah

sistem penilaian risiko yang dipakai di Amerika Serikat untuk membantu keputusan tentang jaminan dan hukuman. Sebuah investigasi jurnalistik menemukan bahwa sistem itu menghasilkan tingkat kesalahan yang berbeda antar kelompok ras, meskipun akurasi keseluruhannya sebanding.

Yang membuat kasus ini penting bukan kesimpulannya, melainkan struktur persoalannya. Ketika para ahli mulai meneliti, mereka menemukan bahwa definisi keadilan yang berbeda tidak bisa dipenuhi sekaligus. Ini bukan pendapat politik; ini hasil matematis.

Mari kita lihat tiga definisi keadilan yang paling sering diusulkan. Yang pertama, *kalibrasi (calibration)*: prediksi dengan tingkat keyakinan tertentu harus benar pada tingkat yang sama untuk semua kelompok. Yang kedua, *kesempatan yang setara (equalised odds)*: tingkat kesalahan harus sama di semua kelompok. Yang ketiga, *paritas demografis (demographic parity)*: hasil akhir harus terdistribusi sama di semua kelompok. Ketiga definisi ini masuk akal ketika dibaca satu per satu. Tetapi ketika kelompok-kelompok yang dibandingkan memiliki tingkat dasar yang berbeda, dan ini hampir selalu terjadi dalam praktik, mustahil memenuhi ketiganya sekaligus. Ini bukan keterbatasan teknologi. Ini adalah hasil yang bisa dibuktikan secara matematis.

Implikasinya tidak nyaman. Ketika seseorang mengatakan sebuah algoritma "adil", ia harus menyebutkan keadilan versi apa yang dimaksud. Ketika dua orang berdebat tentang keadilan sebuah sistem, mereka mungkin sebenarnya berbicara tentang dua definisi yang berbeda, dan keduanya benar menurut definisinya masing-masing. Pilihan di antara definisi-definisi itu adalah pilihan nilai, bukan pilihan teknis, dan pilihan nilai itu tidak bisa didelegasikan ke algoritma.

Konsekuensi praktisnya adalah bahwa mengurangi bias bukan semata-mata pekerjaan teknis. Menghapus atribut yang dilindungi seperti jenis kelamin atau ras dari data tidak dengan sendirinya menghilangkan pengaruhnya, karena atribut-atribut lain yang berkorelasi tetap membawa informasi yang sama. Menyeimbangkan data pelatihan akan mengubah satu ukuran keadilan dengan mengorbankan ukuran yang lain. Pertanyaan tentang ukuran mana yang harus diprioritaskan, dan kepentingan siapa yang harus dilindungi, adalah pertanyaan tentang nilai. Itu adalah pertanyaan yang harus dijawab oleh institusi yang memiliki legitimasi untuk menjawabnya.

6.2 Privasi dan hak atas data

Pembelajaran mesin dilatih pada data, dan sebagian besar data itu adalah tentang orang. Tiga persoalan muncul, dan masing-masing memerlukan perlakuan yang berbeda.

Yang pertama, tentang persetujuan dan pengumpulan. Sebagian besar orang yang datanya dipakai untuk melatih model AI modern tidak pernah menyumbangkannya secara sadar. Teks yang diambil dari web, foto publik, dan perilaku pengguna yang terakumulasi menjadi bahan bakar sistem ini. Apakah penggunaan seperti itu sah, secara hukum masih belum tuntas dan secara etika masih diperdebatkan. Berbagai kerangka hukum di Eropa, Amerika Serikat, dan Indonesia memberikan jawaban yang berbeda. Tidak ada satu jawaban yang diterima secara universal.

Yang kedua, tentang inferensi dan identifikasi ulang. Model bisa menyimpulk-

an atribut sensitif dari data yang tampaknya tidak sensitif. Pola pembelian bisa memprediksi kehamilan. Jejak lokasi bisa memprediksi afiliasi keagamaan. Gaya tulisan bisa memprediksi orientasi seksual dengan akurasi yang cukup tinggi dalam beberapa studi. Bahkan ketika data asli tidak memuat atribut sensitif itu, model yang terlatih bisa memulihkannya. Artinya, privasi tidak terjaga hanya dengan menghapus kolom sensitif dari sebuah kumpulan data.

Yang ketiga, tentang hafalan. Model bahasa besar bisa mereproduksi kembali sebagian data pelatihannya, termasuk informasi pribadi. Fenomena ini sudah didemonstrasikan berulang kali, dan ia adalah konsekuensi langsung dari cara model dilatih: sebuah model yang memampatkan data pelatihannya dengan baik akan menyimpan detail dari data itu. Menghapus konten seperti itu setelah pelatihan sulit; mencegahnya selama pelatihan memerlukan penyaringan korpus atau perubahan tujuan pelatihan, dan keduanya memiliki biaya.

Posisi yang praktis adalah bahwa privasi bukan properti biner. Ia bukan sesuatu yang anda miliki atau tidak miliki. Pertanyaan yang relevan, yaitu siapa yang mengumpulkan data, dengan syarat apa, untuk tujuan apa, dan dengan hak apa untuk menggugat, adalah pertanyaan institusional, bukan pertanyaan teknis. Alat-alat teknis seperti privasi diferensial, pembelajaran terfederasi, dan minimalisasi data bisa mengurangi risiko tertentu, tetapi mereka tidak menggantikan tata kelola.

6.3 Kebijakan: siapa yang berhak memutuskan?

Ketika kita berbicara tentang etika AI, kita sering berhenti pada pertanyaan tentang apa yang harus dilakukan. Tetapi ada pertanyaan yang lebih sulit: siapa yang berhak memutuskan? Pertanyaan ini jarang diangkat, dan justru di situ letak persoalannya.

Tata kelola AI saat ini melibatkan sejumlah kecil pemerintah, sejumlah kecil perusahaan, dan sekelompok organisasi masyarakat sipil yang jumlahnya terus bertambah. Keputusan yang sedang dibuat, tentang risiko apa yang bisa diterima, tentang penggunaan apa yang diizinkan, tentang bagaimana manfaat dan risiko didistribusikan, mempengaruhi populasi yang suaranya kecil dalam proses itu. Ini bukan masalah teknis. Ini masalah politik dan kelembagaan.

Ada beberapa pendekatan yang sedang dicoba di berbagai negara. Sebagian yurisdiksi memilih pendekatan berbasis risiko: sistem yang dianggap berisiko tinggi mendapat persyaratan yang lebih ketat, sistem berisiko rendah mendapat persyaratan yang lebih ringan. Sebagian lain memilih pendekatan sektoral: aturan yang sudah ada di kesehatan, keuangan, dan sektor lain diperluas untuk mencakup sistem AI yang dipakai di dalamnya. Kedua pendekatan ini sering dipakai bersamaan, dan keduanya menghadapi kesulitan yang sama: teknologi bergerak lebih cepat daripada proses regulasi.

Standar teknis, seperti kerangka manajemen risiko yang dikeluarkan oleh lembaga-lembaga standar nasional dan internasional, menyediakan kosakata bersama untuk menilai risiko. Standar-standar ini biasanya bersifat sukarela, tetapi sering menjadi persyaratan *de facto* melalui pengadaan dan tanggung jawab hukum.

Koordinasi internasional lebih sulit lagi. Pengembangan AI bersifat internasional, dan perbedaan regulasi antar negara menciptakan peluang arbitrase: orga-

nisasi bisa mengembangkan di satu yurisdiksi dan menerapkan di yurisdiksi lain. Koordinasi yang bermakna pada persoalan keselamatan, terutama di bidang yang berkaitan dengan militer, sejauh ini terbatas.

Tetapi pertanyaan terpenting bukan apa yang harus diatur. Pertanyaan terpenting adalah siapa yang berhak memutuskan. Dan pada titik ini, kita harus jujur bahwa tata kelola AI saat ini masih jauh dari memadai. Keputusan yang berdampak pada ratusan juta orang dibuat oleh sejumlah kecil aktor, dan sebagian besar orang yang terkena dampaknya tidak memiliki suara dalam proses itu.

6.4 Kesenjangan antara prinsip dan praktik

Ada satu pengamatan yang perlu ditutup di bagian ini, dan ia adalah salah satu yang paling sering diabaikan dalam diskusi publik tentang etika AI.

Dalam satu dekade terakhir, ratusan organisasi menerbitkan pernyataan prinsip tentang AI yang bertanggung jawab. Sebagian besar pernyataan ini berisi nilai-nilai yang sulit dibantah: keadilan, transparansi, akuntabilitas, kemanusiaan. Tetapi jumlah organisasi yang mengubah praktik rekayasa mereka, insentif mereka, atau keputusan penerapan mereka sebagai tanggapan atas prinsip-prinsip itu jauh lebih kecil.

Perbedaan ini penting. Sebuah pernyataan prinsip yang tidak disertai dengan penegakan, akuntabilitas, atau konsekuensi bukanlah mekanisme tata kelola. Ia adalah artefak komunikasi. Ia mungkin bermakna bagi organisasi yang menerbitkannya, dan mungkin mencerminkan niat baik yang tulus. Tetapi ia tidak mengubah cara kerja sistem.

Ini bukan alasan untuk sinisme. Ini alasan untuk memperhatikan mekanisme akuntabilitas. Siapa yang bertanggung jawab ketika sebuah sistem menyebabkan kerugian? Apa yang bisa dilakukan pihak yang dirugikan? Apa yang berubah sebagai akibatnya? Pertanyaan-pertanyaan ini jarang dijawab dalam dokumen-dokumen prinsip, dan justru mereka yang paling menentukan apakah prinsip-prinsip itu berarti.

Bagi pembaca yang bukan spesialis, ini mungkin tampak seperti persoalan yang jauh dari kehidupan sehari-hari. Tetapi ia sebenarnya sangat dekat. Setiap kali anda berinteraksi dengan sistem AI, apakah sebagai pengguna, sebagai warga negara, atau sebagai pekerja, anda adalah bagian dari sistem yang lebih besar. Sistem itu memiliki aturan, insentif, dan mekanisme akuntabilitas, atau ketiadaannya. Memahami di mana anda berada di dalam sistem itu adalah bagian dari memahami AI sebagai fenomena sosial, bukan hanya sebagai fenomena teknis.

Pembaca yang ingin versi lebih rinci dari bagian ini, termasuk pembahasan tentang regulasi, standar, dan kerangka tata kelola yang sedang berkembang di berbagai negara, dapat merujuk ke artikel bahasa Inggris pada Bagian 11.

7 Masa Depan: Skenario, Bukan Ramalan

Bagian-bagian sebelumnya membahas apa yang sudah terjadi dan apa yang sudah kita ketahui. Bagian ini membahas apa yang belum terjadi. Pembahasannya memerlukan disiplin yang berbeda. Ketika kita berbicara tentang masa lalu, kita bisa

merujuk pada bukti. Ketika kita berbicara tentang masa depan, kita hanya bisa bernalar, dan sejarah bidang ini menunjukkan bahwa bernalar tentang masa depan AI memiliki rekam jejak yang buruk. Ingat kembali proposal lokakarya Dartmouth tahun 1956 yang saya sebutkan di artikel bahasa Inggris: sekelompok peneliti terkemuka memperkirakan bahwa sepuluh orang bisa menyelesaikan sebagian besar masalah kecerdasan mesin dalam dua bulan. Mereka keliru dengan margin yang sangat lebar.

Untuk alasan itu, bagian ini membedakan tiga jenis klaim. *Tren* adalah kelanjutan dari perilaku terukur yang sudah terjadi: biaya komputasi turun, jumlah data tumbuh, performa pada tolok ukur tertentu meningkat. *Ekstrapolasi* memproyeksikan tren ke depan dengan asumsi yang mungkin berlaku dan mungkin tidak. *Skenario* menggambarkan kemungkinan masa depan secara koheren, tanpa mengklaim bahwa kemungkinan itu besar. Bagian ini akan berakhir dengan skenario, bukan dengan ramalan, karena itu adalah satu-satunya bentuk argumen yang jujur.

7.1 Pertanyaan yang tidak bisa dijawab

Sebelum masuk ke skenario, ada satu pertanyaan yang paling sering diajukan dan paling sering dijawab dengan terlalu percaya diri: kapan kecerdasan umum buatan, atau AGI, akan tiba? Sebagaimana sudah disinggung di Bagian 2, AGI adalah sistem hipotetis yang bisa menjalankan setiap tugas intelektual yang bisa dilakukan manusia, memindahkan pengetahuan antar domain tanpa pelatihan ulang. Sistem seperti ini belum ada.

Ada dua posisi besar dalam diskusi tentang apakah dan kapan ia akan ada. Posisi pertama, yang bisa disebut posisi skala, berargumen bahwa arsitektur yang ada sekarang, dilatih pada lebih banyak data dengan lebih banyak komputasi, akan terus membaik dan akhirnya mencapai keluasan kemampuan yang setara manusia. Bukti yang diajukan adalah keteraturan empiris dari hukum skala, keluasan kemampuan yang sudah ditunjukkan model bahasa, dan ketiadaan penghalang yang jelas. Posisi kedua, yang bisa disebut posisi arsitektur, berargumen bahwa sistem saat ini kehilangan sesuatu yang struktural. Mereka mempelajari korelasi, bukan sebab. Mereka tidak memiliki memori jangka panjang yang persisten dan perencanaan yang andal. Keluasan yang tampak dari model bahasa lebih tipis daripada kelihatannya. Bukti yang diajukan adalah kerapuhan yang sudah dibahas di Bagian 4 dan Bagian 5.

Kedua posisi ini bisa dipertahankan, dan perdebatan di antara keduanya tidak bisa diselesaikan dengan argumen. Ia akan diselesaikan, jika memang diselesaikan, oleh hasil. Yang bisa kita katakan sekarang adalah bahwa tidak ada pihak yang memiliki rekam jejak prediksi yang akurat. Tenggat waktu yang diucapkan dengan penuh keyakinan, dari kedua sisi, sebaiknya dibaca sebagai pernyataan tentang program riset, bukan sebagai ramalan.

7.2 Tiga skenario yang layak dipertimbangkan

Jika kita tidak bisa meramalkan kapan, kita setidaknya bisa menggambarkan rentang kemungkinan. Tiga skenario berikut tidak saling meniadakan; mereka meng-

gambarkan arah yang berbeda yang bisa terjadi secara bersamaan di berbagai bagian dunia, atau berturut-turut dalam waktu.

Skenario pertama: kelanjutan. AI berkembang sebagai teknologi serbaguna yang tumbuh perlahan, seperti listrik atau internet. Kemampuannya membaik secara bertahap. Penerapannya menyebar secara tidak merata, lebih cepat di beberapa sektor dan lebih lambat di sektor lain. Sebagian pekerjaan berubah, sebagian hilang, dan sebagian baru muncul. Manfaatnya cenderung mengalir ke mereka yang memiliki modal dan keterampilan, seperti yang terjadi pada teknologi serbaguna sebelumnya. Regulasi berkembang perlahan dan tidak merata. Skenario ini bukan utopia dan bukan distopia. Ia adalah kelanjutan dari pola yang sudah kita kenal dari sejarah teknologi.

Skenario kedua: konsentrasi. Kemampuan AI tetap bergantung pada komputasi dan data dalam skala yang hanya bisa dikuasai oleh beberapa organisasi. Manfaat dan kendali atas teknologi memusat pada sejumlah kecil perusahaan dan negara. Akses ke sistem terbaik dimediasi oleh segelintir aktor. Teknologinya sendiri bekerja sangat baik; distribusinya yang menjadi persoalan. Skenario ini sudah sebagian terlihat, dan ia adalah skenario yang paling sering dihilangkan dari diskusi publik, karena ia tidak cocok dengan kerangka kemajuan atau kerangka bencana yang biasa dipakai untuk membingkai AI.

Skenario ketiga: gangguan. Kemampuan AI maju lebih cepat daripada kemampuan institusi untuk menyesuaikan diri. Pergeseran tenaga kerja berlangsung lebih cepat daripada penciptaan peran baru. Tata kelola tertinggal. Misinformasi dan penipuan berkembang lebih cepat daripada penangkalnya. Skenario ini bukan skenario risiko eksistensial, dan ia tidak memerlukan superinteligensi. Ia adalah apa yang terjadi ketika teknologi yang kuat menyebar lebih cepat daripada kerangka yang seharusnya mengelola konsekuensinya. Ia adalah skenario yang paling mungkin terjadi dalam horizon satu dekade, menurut banyak peneliti.

Ketiga skenario ini bukan kategori yang saling meniadakan. Dunia bisa berada di skenario konsentrasi di satu bidang, skenario kelanjutan di bidang lain, dan skenario gangguan di bidang ketiga. Yang penting bukan memilih satu di antara ketiganya, melainkan mengenali bahwa ketiganya mungkin, dan bahwa arah mana yang terwujud bergantung pada pilihan, bukan pada teknologi itu sendiri.

7.3 Yang tidak boleh diabaikan: konsentrasi kekuatan

Dari ketiga skenario di atas, satu aspek perlu dibahas secara khusus: konsentrasi kekuatan. Ini bukan karena skenario konsentrasi lebih mungkin daripada yang lain, tetapi karena ia adalah aspek yang paling jarang dibahas secara jujur.

Persoalannya sederhana. Melatih model AI terdepan memerlukan modal, komputasi, dan data dalam skala yang tidak bisa ditandingi oleh sebagian besar organisasi di dunia. Model bahasa terbesar saat ini dilatih dengan biaya yang diukur dalam puluhan juta dolar Amerika, menggunakan ribuan unit pemrosesan grafis khusus, dan menggunakan korpora teks yang jumlahnya diukur dalam triliunan

kata. Syarat-syarat ini menciptakan konsentrasi kemampuan pada sejumlah kecil aktor.

Konsentrasi ini memiliki implikasi yang berbeda dari konsentrasi di industri lain. Ketika satu perusahaan menjadi besar dalam industri perangkat lunak atau otomotif, pesaing baru bisa muncul dengan membangun produk yang lebih baik. Tetapi ketika satu perusahaan menguasai sumber daya komputasi dan data dalam skala terdepan, pesaing baru tidak memiliki titik masuk yang jelas. Sumber daya itu langka, mahal, dan terikat pada infrastruktur fisik.

Ini bukan argumen bahwa perusahaan besar pasti menyalahgunakan posisinya. Banyak dari mereka secara tulus berusaha memakai teknologi ini secara bertanggung jawab. Tetapi ketika keputusan yang mempengaruhi miliaran orang dibuat oleh sejumlah kecil aktor, pertanyaan tentang legitimasi menjadi relevan, terlepas dari niat baik mereka.

Implikasi praktisnya bagi pembaca bukan spesialis adalah sebagai berikut. Ketika anda mendengar berita tentang kemajuan AI, tanyakan siapa yang memiliki sistem itu dan siapa yang bisa memakainya. Ketika anda mendengar diskusi tentang regulasi AI, tanyakan siapa yang akan menegakkannya dan dengan sumber daya apa. Ketika anda mendengar klaim bahwa AI akan mendemokratisasi akses ke informasi, tanyakan apakah struktur ekonomi di sekitarnya mendukung klaim itu.

7.4 Skenario bukan takdir

Yang paling penting untuk ditekankan di akhir bagian ini adalah bahwa skenario bukan takdir. Masa depan tidak ditentukan oleh teknologi. Ia ditentukan oleh keputusan yang dibuat sekarang, oleh banyak aktor, dalam banyak konteks.

Beberapa keputusan itu bersifat teknis, dan hanya bisa dibuat oleh spesialis. Keputusan tentang arsitektur model, misalnya, atau tentang protokol pelatihan, adalah keputusan yang memerlukan pengetahuan teknis mendalam. Tetapi banyak keputusan yang lebih penting bukan keputusan teknis. Keputusan tentang siapa yang memiliki akses ke sistem terbaik, tentang bagaimana regulasi ditegakkan, tentang di mana investasi publik diarahkan, tentang bagaimana manfaat dan risiko didistribusikan, adalah keputusan yang bisa dan harus dibuat oleh masyarakat luas, termasuk pembaca yang bukan spesialis.

Kesalahan yang paling umum dalam diskusi tentang masa depan AI adalah memperlakukannya sebagai sesuatu yang terjadi pada kita. Padahal ia adalah sesuatu yang kita pilih bersama, atau yang kita biarkan dipilih oleh orang lain tanpa kita. Perbedaan antara kedua kemungkinan itu bukan perbedaan teknologi. Ia adalah perbedaan partisipasi.

Bagian berikutnya, bagian terakhir, akan memberikan anda beberapa alat untuk berpartisipasi: pertanyaan-pertanyaan yang bisa anda pakai untuk menilai klaim tentang AI, dan saran tentang di mana mencari informasi yang lebih dapat dipercaya.

Pembaca yang ingin versi lebih rinci dari bagian ini, termasuk pembahasan tentang AGI yang lebih panjang, dapat merujuk ke artikel bahasa Inggris pada Bagian 12.

8 Ajakan: Apa yang Bisa anda Lakukan

Artikel ini dimulai dengan satu pengamatan: AI adalah teknologi yang dibicarakan di mana-mana, tetapi jarang dijelaskan dengan memadai. Tujuh bagian kemudian, pengamatan itu masih berlaku, tetapi pembaca sekarang memiliki sesuatu yang tidak dimiliki oleh pembaca berita biasa: cara untuk menilai apa yang sedang terjadi.

Bagian ini memberikan tiga hal. Pertama, enam pertanyaan yang bisa anda pakai untuk menilai klaim tentang AI. Kedua, rujukan ke sumber yang lebih dapat dipercaya. Ketiga, sebuah catatan penutup tentang apa artinya memahami AI di zaman ini.

8.1 Enam pertanyaan untuk menilai klaim tentang AI

Setiap hari, anda akan menemukan klaim tentang AI: di berita, di iklan, di obrolan kantor, di media sosial. Sebagian besar klaim ini tidak salah, tetapi juga tidak informatif. Enam pertanyaan berikut bisa membantu anda memisahkan klaim yang bermakna dari yang hanya terdengar mengesankan.

Pertanyaan pertama: apa klaimnya secara tepat? "AI bisa melakukan X" hampir tidak pernah informatif. Apa tugasnya, dalam kondisi apa, dengan metrik apa, dan dibandingkan dengan apa? Model sempit yang menjalankan versi spesifik dari X dalam kondisi spesifik bisa tetap bermakna, tetapi itu bukan kemampuan umum. Ketika anda membaca klaim seperti "AI sekarang bisa mendiagnosis penyakit", tanyakan: penyakit apa, dari data apa, pada populasi siapa, dan dengan akurasi berapa dibandingkan dengan dokter manusia?

Pertanyaan kedua: apa buktinya? Skor tolok ukur adalah bukti tentang tolok ukur itu. Demonstrasi adalah bukti tentang satu contoh. Anekdote, keberhasilan yang dipilih-pilih, dan keluaran yang terlihat mengesankan adalah bentuk bukti yang paling lemah, dan justru yang paling umum dalam diskusi publik. Ketika anda melihat demonstrasi, tanyakan: apakah ini mewakili kinerja rata-rata, atau ini adalah contoh terbaik yang berhasil mereka temukan?

Pertanyaan ketiga: apa tingkat dasarnya, apa pembandingnya? Jika sebuah model dilaporkan memiliki akurasi 95%, apa yang dicapai oleh model sepele? Pengklasifikasi yang selalu memprediksi kelas mayoritas bisa mencapai akurasi tinggi pada data yang tidak seimbang sambil tidak berguna sama sekali. Jika 95% dari surel adalah bukan spam, maka pengklasifikasi yang selalu mengatakan "bukan spam" sudah mencapai akurasi 95%. Angka akurasi tidak berarti apa-apa tanpa pembanding.

Pertanyaan keempat: apa yang terjadi ketika ia salah? Biaya kesalahan bergantung pada domain, dan sama pentingnya dengan frekuensinya. Model yang salah mengklasifikasi digit bisa lucu. Model yang salah mengklasifikasi tumor tidak. Model yang salah merekomendasikan video bisa mengganggu. Model yang salah

merekomendasikan keputusan hukum bisa merusak hidup seseorang. Ketika anda mendengar klaim tentang akurasi, tanyakan: apa yang terjadi pada 5% kasus yang salah, dan siapa yang menanggung akibatnya?

Pertanyaan kelima: siapa yang mendapat manfaat, dan siapa yang menanggung risiko? Sistem AI dipakai di dalam institusi dengan insentif. Distribusi manfaat dan risiko bukan kebetulan. Ia adalah keputusan desain, baik disadari maupun tidak. Ketika anda mendengar tentang sistem baru, tanyakan: siapa yang mendapat manfaat utamanya, dan siapa yang menanggung risiko terbesarnya. Sering kali jawabannya adalah dua kelompok yang berbeda, dan kelompok yang menanggung risiko tidak duduk di meja tempat keputusan dibuat.

Pertanyaan keenam: apa yang akan mengubah klaim ini? Klaim yang tidak bisa dibantah oleh bukti apa pun bukan klaim empiris. Ia mungkin posisi filosofis, mungkin ramalan, mungkin iklan. Ketika seseorang mengklaim sesuatu tentang AI, tanyakan: bukti apa yang akan membuat anda mengubah pikiran? Jika tidak ada, maka klaimnya bukan tentang dunia nyata; ia tentang keyakinan orang yang mengucapkannya.

Keenam pertanyaan ini tidak baru. Mereka adalah alat standar penalaran empiris, dan mereka berlaku pada semua bidang, bukan hanya AI. Yang perlu ditekankan adalah bahwa AI tidak dikecualikan dari standar bukti dan argumen yang biasa. Jika sebuah klaim tentang AI tidak bisa lulus keenam pertanyaan ini, itu bukan karena AI terlalu rumit untuk dinilai. Itu karena klaimnya memang tidak layak dipercaya.

8.2 Di mana mencari informasi lebih lanjut

Artikel ini adalah pengantar. Ia sengaja dibuat pendek, dan ia sengaja menghindari detail teknis yang akan menyulitkan pembaca bukan spesialis. Jika anda ingin lebih dalam, ada beberapa jalan.

Artikel bahasa Inggris yang menjadi rujukan artikel ini. Artikel yang lebih panjang dalam bahasa Inggris membahas setiap topik di sini dengan lebih rinci. Ia menyertakan persamaan matematis, pembahasan teknis yang lebih mendalam, catatan tentang sumber dan kualitas bukti, glosarium istilah, dan daftar pustaka beranotasi. Ia tersedia di alamat yang tercantum di awal artikel ini, dan versinya juga dipelihara sebagai dokumen yang bisa dikembangkan.

Notebook Python yang menyertai artikel bahasa Inggris. Semua eksperimen yang disebut di artikel ini bisa dijalankan sendiri dalam sebuah notebook Python. Notebook itu membangun model dari awal, menunjukkan proses pelatihan langkah demi langkah, dan memperlihatkan di mana model gagal. Ia dirancang untuk berjalan di komputer biasa dalam waktu kurang dari sepuluh menit. Bagi pembaca yang ingin merasakan sendiri bagaimana AI bekerja, ini adalah jalan yang paling langsung.

Buku dan sumber lain. Untuk pembaca yang ingin mendalami lebih jauh, ada beberapa buku yang layak dibaca. Untuk pengantar yang lebih luas, buku *Artificial Intelligence: A Modern Approach* oleh Russell dan Norvig adalah rujukan standar, meskipun ia tebal dan lebih cocok sebagai buku referensi daripada bacaan singkat. Untuk pemahaman tentang bagaimana AI dipakai dan disalahgunakan di dunia nyata, buku-buku jurnalisme teknologi seperti karya Cathy O’Neil dan Virginia Eubanks memberikan perspektif yang tidak selalu muncul di tulisan teknis. Untuk pembaca Indonesia, ada baiknya juga mengikuti diskusi kebijakan yang sedang berkembang, baik di tingkat nasional maupun internasional, karena banyak keputusan penting sedang dibuat sekarang.

Satu peringatan tentang sumber. Tidak semua yang ditulis tentang AI bisa dipercaya. Sebagian besar berita tentang AI ditulis dengan cepat dan tanpa verifikasi yang memadai. Sebagian besar pengumuman produk adalah pemasaran, bukan laporan teknis. Sebagian besar ramalan tentang masa depan AI adalah spekulasi yang disajikan sebagai fakta. Ketika anda membaca sesuatu tentang AI, coba ingat kembali keenam pertanyaan di atas. Semakin banyak pertanyaan yang bisa dijawab dengan baik oleh penulisnya, semakin layak sumber itu dipercaya.

8.3 Penutup

Ada satu pesan yang ingin saya tinggalkan di akhir artikel ini, dan ia adalah pesan yang sama yang muncul di setiap bagian.

AI bukan sihir. Ia bukan alien yang datang dari luar untuk mengubah nasib manusia. Ia adalah alat yang dibuat manusia, dilatih pada pengetahuan manusia, dan dipakai oleh manusia. Kemampuannya nyata, dan sebagian di antaranya mengesankan. Keterbatasannya juga nyata, dan sebagian di antaranya serius. Ia akan terus berkembang, dan perkembangannya akan mempengaruhi banyak hal di kehidupan kita, tetapi ia tidak akan menentukan sendiri arah perkembangannya.

Yang menentukan arah adalah keputusan-keputusan yang dibuat oleh banyak orang, dalam banyak konteks, dengan banyak kepentingan. Sebagian dari keputusan itu dibuat oleh perusahaan besar. Sebagian dibuat oleh pemerintah. Sebagian dibuat oleh peneliti. Dan sebagian dibuat oleh masyarakat umum, termasuk anda, baik melalui pilihan yang anda buat sebagai konsumen, melalui suara yang anda berikan sebagai warga negara, maupun melalui percakapan yang anda lakukan dengan orang-orang di sekitar anda.

Artikel ini adalah satu upaya kecil untuk membekali anda menghadapi percakapan-percakapan itu. Ia tidak akan membuat anda menjadi ahli AI, dan mungkin anda tidak perlu menjadi ahli. Yang diperlukan bukan keahlian teknis, tetapi kemampuan untuk membaca klaim dengan kritis, untuk mengenali keterbatasan, dan untuk tidak terjebak dalam kepanikan maupun kegilaan. Kemampuan-kemampuan ini bukan hal yang mewah. Mereka adalah bagian dari apa yang membuat seseorang menjadi warga negara yang baik di zaman ketika teknologi bergerak lebih cepat daripada pemahaman publik tentangnya.

Jika anda mengingat satu hal saja dari artikel ini, biarlah itu menjadi ini: AI tidak memahami apa yang ia lakukan, dan kita tidak sepenuhnya memahami menga-

pa ia bekerja. Yang bisa kita lakukan, dan yang harus kita lakukan, adalah memakai alat ini dengan mata terbuka, memperhatikan di mana ia gagal, dan memastikan bahwa manfaat dan risikonya didistribusikan secara adil. Itu bukan pekerjaan satu orang. Itu adalah pekerjaan kita bersama.

A Catatan tentang Istilah

Lampiran ini berisi istilah teknis yang muncul dalam artikel ini, dengan padanan bahasa Inggrisnya dan penjelasan singkat. Istilah disusun menurut abjad. Istilah yang dicetak miring adalah istilah Inggris yang dibiarkan dalam artikel ini karena padanan Indonesianya jarang dipakai atau justru membingungkan.

AI generatif (*generative AI*) Kategori sistem AI yang menghasilkan konten baru, seperti teks, gambar, suara, atau kode, bukan hanya mengklasifikasi atau memprediksi. Model bahasa besar dan model difusi termasuk di dalamnya. Kategori ini didefinisikan oleh keluarannya, bukan oleh metodenya.

AI sempit (*narrow AI*) Sistem AI yang menjalankan satu tugas tertentu atau sekelompok tugas yang berkaitan. Semua sistem AI yang dipakai saat ini, termasuk model bahasa besar, adalah sempit dalam pengertian ini.

Backpropagation (perambatan balik) Algoritma yang menghitung seberapa besar setiap parameter di dalam model berkontribusi terhadap kesalahan yang dibuat. Ini adalah langkah ketiga dalam siklus pelatihan lima langkah yang dijelaskan di Bagian 3.

Deep learning (pembelajaran mendalam) Bagian dari pembelajaran mesin yang memakai jaringan saraf dengan banyak lapisan. Kata “mendalam” merujuk pada kedalaman komposisi antar lapisan.

Distribution shift (pergeseran distribusi) Kesenjangan antara distribusi data yang dipakai untuk melatih model dan distribusi data yang dihadapinya di dunia nyata. Ini adalah penyebab paling umum kegagalan sistem AI ketika sudah dipakai, seperti dibahas di Bagian 5.

Double descent Fenomena empiris di mana kesalahan uji model tidak terus naik seiring bertambahnya kompleksitas, seperti yang diprediksi teori klasik, tetapi turun kembali setelah melewati titik interpolasi. Dijelaskan di Bagian 4.

Fine-tuning (penyetelan halus) Pelatihan lanjutan pada model yang sudah dilatih sebelumnya, biasanya pada kumpulan data yang lebih kecil dan lebih spesifik. Istilah ini dibiarkan dalam bahasa Inggris karena padanan Indonesianya jarang dipakai.

Gradient descent (penurunan gradien) Metode standar untuk melatih model AI. Ia menyesuaikan parameter model sedikit demi sedikit, ke arah yang mengurangi kesalahan. Dijelaskan dengan analogi lereng gunung di Bagian 3.

Grokking Fenomena empiris di mana model tampak menghafal data pelatihan selama ribuan langkah, lalu tiba-tiba berpindah ke solusi yang bisa digeneralisasi. Dijelaskan di Bagian 4.

Jaringan saraf (*neural network*) Arsitektur komputasi yang terdiri atas lapisan-lapisan unit sederhana yang saling terhubung. Setiap koneksi memiliki bobot yang disesuaikan selama pelatihan. Ini adalah fondasi sebagian besar AI modern.

Kecerdasan buatan (*artificial intelligence*, AI) Istilah paling luas, merujuk pada setiap usaha membuat mesin menjalankan tugas yang, jika dilakukan manusia, dianggap memerlukan kecerdasan. Lihat definisi baku di Bagian 2.

Kecerdasan mesin Istilah yang kadang dipakai sebagai sinonim untuk kecerdasan buatan, terutama dalam konteks teknis. Dalam artikel ini, istilah ini dipakai bergantian dengan "kecerdasan buatan" untuk variasi gaya, tanpa perbedaan makna.

Kecerdasan umum buatan (*artificial general intelligence*, AGI) Sistem hipotetis yang bisa menjalankan setiap tugas intelektual yang bisa dilakukan manusia. Sistem seperti ini belum ada.

Loss function (fungsi kerugian) Ukuran kesalahan model, berupa satu angka yang merangkum seberapa jauh prediksi model dari jawaban yang benar. Pelatihan bertujuan meminimalkan angka ini.

Machine learning (pembelajaran mesin) Bagian dari AI di mana sistem belajar pola dari data, bukan diprogram dengan aturan eksplisit.

Model bahasa besar (*large language model*, LLM) Model AI yang dilatih untuk memprediksi kata berikutnya dalam urutan, biasanya dengan jumlah parameter yang sangat besar. Model yang mendasari *chatbot* modern seperti ChatGPT termasuk dalam kategori ini.

Overfitting (terlalu cocok) Kegagalan model karena terlalu menghafal data pelatihan, sehingga tidak bisa bekerja pada data baru. Lihat Bagian 4 untuk pembahasan tentang mengapa AI modern sering kali menghindari kegagalan ini meskipun ukurannya sangat besar.

Parameter Angka di dalam model yang disesuaikan selama pelatihan. Parameter inilah yang disimpan setelah pelatihan selesai, dan parameter inilah yang dipakai ketika model menjalankan tugasnya.

Prompt (perintah) Teks masukan yang diberikan kepada model bahasa besar. Istilah ini dibiarkan dalam bahasa Inggris karena sudah lazim dipakai di komunitas pengguna.

Scaling laws (hukum skala) Pola empiris yang menunjukkan bahwa performa model AI membaik secara teratur seiring bertambahnya ukuran model, jumlah data, dan daya komputasi. Dibahas di Bagian 3.

Superinteligensi Sistem hipotetis yang kemampuannya jauh melampaui manusia terbaik di semua bidang yang relevan. Ia bukan target rekayasa, dan tidak ada sistem saat ini yang berada di jalur yang masuk akal menuju ke sana.

Token (potongan kata) Unit terkecil yang diproses oleh model bahasa. Satu kata bisa terdiri atas beberapa *token*, dan satu *token* bisa berupa potongan kata. Dalam artikel ini, istilah *token* dipakai dengan penjelasan singkat pada kemunculan pertama.

Transformer Arsitektur jaringan saraf yang diperkenalkan pada tahun 2017 dan menjadi dasar hampir semua model bahasa besar saat ini. Istilah ini selalu dibiarkan dalam bahasa Inggris.

Underfitting (kurang cocok) Kegagalan model karena terlalu sederhana untuk menangkap pola data. Kebalikan dari *overfitting*.

Daftar ini tidak lengkap. Ia hanya memuat istilah yang benar-benar muncul di artikel ini. Untuk istilah lain yang mungkin anda temui ketika membaca tentang AI, cara paling praktis adalah mencari padanan Inggrisnya terlebih dahulu, karena sebagian besar literatur teknis ditulis dalam bahasa Inggris.

B Bacaan Lebih Lanjut

Artikel ini adalah pengantar, bukan rujukan lengkap. Jika anda ingin mendalami topik yang dibahas di sini, rujukan utamanya adalah artikel bahasa Inggris yang menjadi sumber artikel ini. Artikel itu tersedia di alamat yang tercantum di awal dokumen ini, dan ia menyertakan daftar pustaka beranotasi yang tersusun menurut tema, dari pengantar umum sampai literatur teknis tentang keterbatasan, interpretabilitas, dan etika AI.

Selain artikel itu, ada dua sumber yang bisa anda pertimbangkan.

Notebook Python yang menyertai artikel bahasa Inggris adalah jalan paling langsung untuk merasakan bagaimana AI bekerja. Ia membangun model dari awal, menunjukkan setiap langkah dalam proses pelatihan, dan memperlihatkan di mana model gagal. Ia dirancang untuk berjalan di komputer biasa dalam waktu kurang dari sepuluh menit, dan anda tidak perlu menjadi pemrogram untuk menjalankannya.

Untuk pembaca yang ingin mengikuti perkembangan terkini, sumber yang paling dapat dipercaya adalah jurnal ilmiah seperti *Nature* dan *Science*, serta konferensi utama di bidang ini seperti NeurIPS, ICML, dan ICLR. Sebagian besar materi ini berbahasa Inggris dan cukup teknis. Sebagian besar berita tentang AI di media umum ditulis dengan cepat dan tanpa verifikasi yang memadai, dan keenam pertanyaan di Bagian 8 bisa dipakai untuk menilai klaim yang anda temui di sana.

Satu catatan tentang bahasa. Sebagian besar literatur teknis tentang AI, termasuk buku-buku yang menjadi rujukan standar, umumnya berbahasa Inggris. Pembaca yang ingin mendalami bidang ini pada tingkat teknis hampir pasti akan bekerja dengan materi berbahasa Inggris. Ini bukan alasan untuk berhenti, tetapi sesuatu yang perlu diketahui sejak awal.

B.1 Catatan Penutup

Jalan untuk memahami AI tidak tunggal. Sebagian orang merasa paling terbantu dengan membaca buku-buku panjang. Sebagian lain lebih terbantu dengan mencoba kode secara langsung. Sebagian lagi lebih terbantu dengan berdiskusi dalam kelompok atau komunitas. Apa pun jalan yang anda pilih, yang penting bukan penguasaan detail teknis. Yang penting adalah kesediaan untuk membaca dengan kritis, mengakui ketika anda tidak memahami sesuatu, dan terus bertanya.

Artikel ini adalah satu titik awal. Yang diharapkan adalah bahwa setelah membacanya, anda merasa lebih siap menghadapi percakapan tentang AI yang akan anda temui di pekerjaan, di berita, dan di kehidupan sehari-hari.